

Perbandingan Metode Clustering Berdasarkan Validasi Cluster

Sistem Machine Learning

Clara Angelina (3338240011)

2026-06-02

Deskripsi Dataset

Sumber dan Konteks Data

Dataset *Wine Quality* tersedia secara publik di UCI Machine Learning Repository, dikembangkan oleh *A. Cerdeira, F. Almeida, T. Matos, dan J. Reis (2009)* dan dapat diakses di: <https://archive.ics.uci.edu/dataset/186/wine+quality>. Dataset ini berisi informasi mengenai kualitas wine merah (red wine) dan wine putih (white wine) yang diproduksi di wilayah *Vinho Verde, Portugal*.

Setiap baris dalam dataset merepresentasikan satu sampel wine, sedangkan setiap kolom berisi karakteristik fisikokimia yang digunakan untuk menilai kualitas wine tersebut. Dataset ini memiliki 11 variabel prediktor, yaitu fixed acidity, volatile acidity, citric acid, residual sugar, chlorides, free sulfur dioxide, total sulfur dioxide, density, pH, sulphates, dan alcohol, serta 1 variabel target, yaitu quality, yang menunjukkan skor kualitas wine menurut penilaian sensorik para ahli. Dataset ini banyak digunakan dalam penelitian dan pembelajaran machine learning untuk analisis data, klasifikasi, regresi, serta clustering.

Tujuan Analisis

Tugas clustering ini memiliki tujuan analisis sebagai berikut: 1. Memahami karakteristik data wine melalui eksplorasi data dan analisis statistik deskriptif. 2. Melakukan preprocessing data, berupa standarisasi (scaling), untuk memastikan seluruh variabel memiliki skala yang sebanding dalam proses clustering. 3. Mengelompokkan sampel wine berdasarkan kemiripan karakteristik fisikokimianya menggunakan metode **K-Means Clustering** dan **Hierarchical Clustering**. 4. Mengevaluasi kualitas cluster yang terbentuk menggunakan metode validasi

cluster yang sesuai. 5. Membandingkan hasil pengelompokan dari metode K-Means dan Hierarchical Clustering untuk menentukan metode yang memberikan performa terbaik. 5. Mengevaluasi kualitas cluster menggunakan metode validasi cluster yang sesuai, seperti Silhouette Coefficient, Davies-Bouldin Index, atau indeks validasi lainnya. 6. Menginterpretasikan karakteristik setiap cluster yang terbentuk sehingga diperoleh pemahaman mengenai pola alami dan segmentasi sampel wine berdasarkan sifat kimianya.

Input dan Eksplorasi Data Awal

```
library(readxl)
library(cluster)
library(factoextra)
wine <- read_excel("~/Documents/SML_T4/Dataset_Soal2.xlsx")
cat("Dimensi dataset:", nrow(wine), "baris x", ncol(wine), "kolom\n")

Dimensi dataset: 1599 baris x 12 kolom

str(wine)

tibble [1,599 × 12] (S3: tbl_df/tbl/data.frame)
 $ fixed acidity      : num [1:1599] 7.4 7.8 7.8 11.2 7.4 7.4 7.9 7.3 7.8
7.5 ...
 $ volatile acidity   : num [1:1599] 0.7 0.88 0.76 0.28 0.7 0.66 0.6 0.65
0.58 0.5 ...
 $ citric acid        : num [1:1599] 0 0 0.04 0.56 0 0 0.06 0 0.02 0.36 ...
 $ residual sugar     : num [1:1599] 1.9 2.6 2.3 1.9 1.9 1.8 1.6 1.2 2 6.1
...
 $ chlorides          : num [1:1599] 0.076 0.098 0.092 0.075 0.076 0.075
0.069 0.065 0.073 0.071 ...
 $ free sulfur dioxide : num [1:1599] 11 25 15 17 11 13 15 15 9 17 ...
 $ total sulfur dioxide: num [1:1599] 34 67 54 60 34 40 59 21 18 102 ...
 $ density            : num [1:1599] 0.998 0.997 0.997 0.998 0.998 ...
 $ pH                : num [1:1599] 3.51 3.2 3.26 3.16 3.51 3.51 3.3 3.39
3.36 3.35 ...
 $ sulphates          : num [1:1599] 0.56 0.68 0.65 0.58 0.56 0.56 0.46 0.47
0.57 0.8 ...
 $ alcohol            : num [1:1599] 9.4 9.8 9.8 9.8 9.4 9.4 9.4 10 9.5 10.5
...
 $ quality            : num [1:1599] 5 5 5 6 5 5 5 7 7 5 ...

sum(is.na(wine))

[1] 0
```

Preprocessing Data (Scalling)

```
wine_features <- wine[, 1:11]      # hapus variabel quality
wine_scaled <- scale(wine_features) # scalling data
```

```
summary(wine)                      # sebelum scalling
```

fixed acidity	volatile acidity	citric acid	residual sugar
Min. : 4.60	Min. : 0.1200	Min. : 0.000	Min. : 0.900
1st Qu.: 7.10	1st Qu.: 0.3900	1st Qu.: 0.090	1st Qu.: 1.900
Median : 7.90	Median : 0.5200	Median : 0.260	Median : 2.200
Mean : 8.32	Mean : 0.5278	Mean : 0.271	Mean : 2.539
3rd Qu.: 9.20	3rd Qu.: 0.6400	3rd Qu.: 0.420	3rd Qu.: 2.600
Max. : 15.90	Max. : 1.5800	Max. : 1.000	Max. : 15.500
chlorides	free sulfur dioxide	total sulfur dioxide	density
Min. : 0.01200	Min. : 1.00	Min. : 6.00	Min. : 0.9901
1st Qu.: 0.07000	1st Qu.: 7.00	1st Qu.: 22.00	1st Qu.: 0.9956
Median : 0.07900	Median : 14.00	Median : 38.00	Median : 0.9968
Mean : 0.08747	Mean : 15.87	Mean : 46.47	Mean : 0.9967
3rd Qu.: 0.09000	3rd Qu.: 21.00	3rd Qu.: 62.00	3rd Qu.: 0.9978
Max. : 0.61100	Max. : 72.00	Max. : 289.00	Max. : 1.0037
pH	sulphates	alcohol	quality
Min. : 2.740	Min. : 0.3300	Min. : 8.40	Min. : 3.000
1st Qu.: 3.210	1st Qu.: 0.5500	1st Qu.: 9.50	1st Qu.: 5.000
Median : 3.310	Median : 0.6200	Median : 10.20	Median : 6.000
Mean : 3.311	Mean : 0.6581	Mean : 10.42	Mean : 5.636
3rd Qu.: 3.400	3rd Qu.: 0.7300	3rd Qu.: 11.10	3rd Qu.: 6.000
Max. : 4.010	Max. : 2.0000	Max. : 14.90	Max. : 8.000

```
summary(wine_scaled)              # setelah scalling
```

fixed acidity	volatile acidity	citric acid	residual sugar
Min. : -2.1364	Min. : -2.27757	Min. : -1.39104	Min. : -1.1623
1st Qu.: -0.7005	1st Qu.: -0.76969	1st Qu.: -0.92903	1st Qu.: -0.4531
Median : -0.2410	Median : -0.04367	Median : -0.05634	Median : -0.2403
Mean : 0.00000	Mean : 0.000000	Mean : 0.000000	Mean : 0.00000
3rd Qu.: 0.5056	3rd Qu.: 0.62649	3rd Qu.: 0.76501	3rd Qu.: 0.0434
Max. : 4.3538	Max. : 5.87614	Max. : 3.74240	Max. : 9.1928
chlorides	free sulfur dioxide	total sulfur dioxide	density
Min. : -1.60344	Min. : -1.4221	Min. : -1.2302	Min. : -3.53762
1st Qu.: -0.37111	1st Qu.: -0.8485	1st Qu.: -0.7438	1st Qu.: -0.60757
Median : -0.17989	Median : -0.1792	Median : -0.2574	Median : 0.00176
Mean : 0.00000	Mean : 0.00000	Mean : 0.00000	Mean : 0.000000
3rd Qu.: 0.05383	3rd Qu.: 0.4900	3rd Qu.: 0.4722	3rd Qu.: 0.57664
Max. : 11.12355	Max. : 5.3656	Max. : 7.3728	Max. : 3.67890
pH	sulphates	alcohol	
Min. : -3.69924	Min. : -1.9359	Min. : -1.8983	
1st Qu.: -0.65494	1st Qu.: -0.6380	1st Qu.: -0.8661	
Median : -0.00721	Median : -0.2251	Median : -0.2092	
Mean : 0.00000	Mean : 0.00000	Mean : 0.00000	

3rd Qu.: 0.57574	3rd Qu.: 0.4239	3rd Qu.: 0.6353
Max. : 4.52687	Max. : 7.9162	Max. : 4.2011


Metode Clustering

K-Means Clustering

Penentuan Jumlah Cluster (k) Optimal

Elbow Method

```
fviz_nbclust(wine_scaled, kmeans, method = "wss") +  
  labs(title = "Elbow Method - Red Wine Quality",  
        subtitle = "Menentukan jumlah cluster optimal (k)",  
        x = "Jumlah Cluster (k)",  
        y = "Total Within Sum of Squares")
```



Silhouette Method

```
fviz_nbclust(wine_scaled, kmeans, method = "silhouette") +  
  labs(title = "Silhouette Score - Red Wine Quality",  
        subtitle = "Nilai tertinggi = jumlah cluster optimal",  
        x = "Jumlah Cluster (k)",  
        y = "Average Silhouette Width")
```



Penentuan jumlah cluster optimal dilakukan dengan menggunakan Elbow Method dan Silhouette Method. Elbow Method dipakai untuk menentukan jumlah cluster yang paling tepat berdasarkan nilai Within Cluster Sum of Squares (WSS). Dari grafik Elbow Method, terlihat bahwa nilai WSS mengalami penurunan yang cukup tajam dari $k = 1$ ke $k = 2$, lalu penurunannya mulai melambat saat melihat jumlah cluster yang lebih banyak. Titik paling ideal terlihat di sekitar $k = 2$, jadi jumlah cluster yang layak digunakan adalah 2 cluster.

Kemudian, dilakukan evaluasi menggunakan Silhouette Method. Dari grafik Silhouette Method, nilai Average Silhouette Width tertinggi ditemukan pada $k = 2$. Nilai ini lebih tinggi dibandingkan dengan jumlah cluster lainnya, yang menandakan bahwa pembentukan dua cluster menghasilkan hasil kekompakan dan pemisahan antar cluster yang paling baik.

Dari hasil Elbow Method dan Silhouette Method, jumlah cluster yang dipilih untuk analisis selanjutnya adalah 2 cluster. Pemilihan ini didasarkan pada kesamaan hasil dari kedua metode yang menunjukkan bahwa $k = 2$ adalah jumlah cluster yang paling optimal untuk dataset Wine Quality.

```
# Menjalankan K-Means
```

```
set.seed(123)
```

```
km_wine <- kmeans(wine_scaled, centers = 2, nstart = 25)
```

```
km_wine
```

K-means clustering with 2 clusters of sizes 590, 1009

Cluster means:

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol
1	0.9207271	-0.6361774	0.9851367	0.16097077	0.2641746	-0.2356324	-0.2152177	0.4994664	-0.7077417	0.5314734	0.1730540
2	-0.5383835	0.3719967	-0.5760462	-0.09412562	-0.1544728	0.1377831	0.1258458	-0.2920566	0.4138430	-0.3107723	-0.1011911

Clustering vector:

```
[1] 2 2 2 1 2 2 2 2 2 2 2 2 2 2 1 2 2 1 1 2 1 1 2 1 2 2 2 2 1 2 2 2 2 2 2 2
2 2
[38] 1 2 1 1 2 1 1 2 2 2 1 2 2 1 2 2 2 2 2 1 2 2 2 2 2 2 2 2 2 2 2 2 2 1 2 2 2
2 2
[75] 1 1 1 2 2 2 2 1 2 1 2 2 1 2 1 2 2 1 1 2 2 2 2 2 2 2 2 2 2 2 2 2 2 1 2 1
2 2
[112] 2 2 1 2 1 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2
2 1
[149] 2 2 1 1 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 1 2
2 2
[186] 1 2 2 2 2 2 2 2 2 2 2 2 2 1 2 2 1 1 2 2 2 1 1 2 2 1 1 2 1 2 2 2 2 2 2 2
2 2
[223] 2 2 2 2 1 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 1 1 2 1 1 2 2 2 2 2 1 2 1 2 2 2 1
2 1
[260] 1 2 2 2 2 1 1 2 1 2 1 2 1 1 2 2 2 2 1 1 1 1 1 2 1 2 2 1 2 2 1 2 1 1 2
1 1
[297] 1 2 2 2 2 1 2 2 1 1 2 1 1 2 1 2 2 2 2 2 2 2 1 2 1 2 2 1 1 1 1 1 1 1 1
1 2
[334] 2 2 1 1 2 1 1 1 1 1 1 1 2 2 1 1 2 1 2 2 1 2 2 1 1 1 1 2 1 1 1 1 1 1 1
1 1
[371] 2 1 1 2 1 1 1 1 1 1 1 1 1 1 2 2 2 2 2 1 2 1 1 1 1 1 2 1 1 2 2 2 1 1 2
1 1
[408] 1 1 1 2 2 2 1 2 1 1 2 1 2 1 2 2 1 2 2 2 2 1 1 1 2 1 1 1 1 2 1 1 2 1 1
1 1
[445] 2 2 1 1 2 1 1 1 2 1 2 1 1 2 1 1 1 1 1 1 1 1 1 2 1 1 1 1 1 1 1 1 1 1
2 1
[482] 1 1 1 1 1 1 1 1 1 2 1 1 2 2 1 2 2 1 2 2 1 1 1 1 1 1 1 1 1 1 1 1 1 1
1 1
[519] 1 2 1 2 1 1 1 1 2 2 1 1 1 1 1 1 1 1 1 2 1 1 1 1 2 1 1 1 2 1 1 1 2 1 1
2 1
```

[556] 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 2 1 2 1 1 1 1 1 1 1 1 1 1 1 1 1 2 1 2 2 1
1 2
[593] 1 1 2 1 1 1 2 1 2 1 2 1 2 2 1 1 1 2 1 1 2 1 1 2 2 1 1 1 2 2 1 2 2 2 2
2 2
[630] 2 2 1 2 2 2 2 2 2 2 1 1 2 1 2 1 2 2 2 2 2 1 2 1 1 1 1 1 1 2 2 2 2 2 1
1 2
[667] 1 1 1 1 2 2 2 2 1 1 1 2 2 1 1 2 2 2 2 2 2 2 2 1 2 2 1 2 2 2 2 2 2 1 1
2 2
[704] 1 2 2 2 2 2 1 1 2 2 2 2 2 2 2 2 2 2 2 2 1 2 2 2 2 2 2 1 2 2 2 2 2 2 2
2 2
[741] 2 2 2 1 1 2 2 1 2 2 2 2 2 2 1 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 1 1
2 2
[778] 2 1 2 2 2 2 2 2 1 1 1 1 2 2 2 2 2 1 1 1 1 1 2 2 2 2 2 1 1 1 2 2 2 1
1 2
[815] 1 1 1 1 2 2 2 2 2 2 2 2 2 2 2 2 2 1 1 2 2 2 2 1 2 1 2 1 2 1 2 2 2 2
2 1
[852] 1 1 2 2 2 2 1 1 2 2 2 2 2 2 2 2 2 2 2 2 2 1 1 1 2 2 2 2 2 2 1 2 2 2
2 1
[889] 2 1 2 2 1 2 2 2 1 2 1 2 1 2 2 2 2 2 2 2 2 2 1 1 1 2 1 2 2 2 2 1 2 2
2 1
[926] 2 1 2 1 1 2 2 2 2 2 1 1 1 2 2 1 1 1 1 1 1 1 1 1 1 1 1 1 1 2 1 1 1 2 2
1 2
[963] 2 1 1 1 1 2 1 2 1 1 1 1 1 2 2 2 2 1 1 2 2 1 1 2 1 2 2 1 2 2 2 2 1 2 2
2 2
[1000] 2 2 1 1 2 2 2 1 1 1 1 1 1 2 2 2 1 1 2 2 2 1 1 2 1 2 2 2 2 2 2 2 2 2 2
2 1
[1037] 2 2 1 2 2 2 2 1 2 2 2 2 1 1 2 1 2 1 2 2 1 2 1 1 1 1 1 1 2 2 2 1 1 2 1
2 2
[1074] 2 2 1 1 1 1 1 1 1 2 1 2 2 1 1 1 1 1 2 1 2 1 2 1 1 1 1 2 2 2 2 2 1 1
2 1
[1111] 2 2 1 1 2 2 2 2 2 2 2 2 2 2 1 2 1 2 2 1 1 2 2 2 2 1 2 1 1 2 2 2 1 2 2 2
1 2
[1148] 1 2 1 1 2 2 1 2 2 1 2 1 1 1 1 1 2 2 1 1 1 2 2 1 2 1 2 2 2 2 2 2 1 1 1
1 2
[1185] 2 2 2 2 2 2 1 2 2 2 2 2 2 2 1 2 2 2 1 2 2 2 2 1 2 2 2 2 2 1 1 1 2 2 1
1 1
[1222] 1 2 1 1 1 2 1 2 2 1 2 2 1 2 2 2 2 2 2 2 1 1 2 2 2 2 2 2 2 2 2 2 2 2 2
2 2
[1259] 2 2 1 2 1 2 2 2 2 1 2 2 2 2 2 2 2 2 2 2 1 2 2 1 2 2 2 2 2 1 2 2 1 1 2 2 2
2 2
[1296] 2 2 2 2 2 2 2 1 2 2 2 2 2 2 2 2 2 2 2 2 2 2 1 2 1 1 2 1 1 2 2 2 2 2 2
2 2
[1333] 2 2 2 2 2 2 2 2 2 2 2 2 1 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 1 1 2 1 2 2 2 2
1 2
[1370] 2 1 1 1 2 1 1
2 1
[1407] 1 2 1 2 2 2 1 1 1 2 1 2 2 2 2 2 2 2 1 1 1 2 2 1 2 2 2 2 1 1 1 2 2 2 2
2 2
[1444] 2 2 2 2 2 2 2 2 1 2 2 1 2 2 2 1 1 2 2 2 2 2 2 2 2 2 2 2 2 2 1 2 1 2 1 2
2 1

```
[1481] 2 1 1 1 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 1 2 2 1 1 1 2 2 2 2 2
2 2
[1518] 2 1 2 2 2 2 2 2 2 2 2 1 2 2 2 2 2 2 2 2 2 2 2 2 2 1 1 2 2 2 1 2 2 2
2 2
[1555] 2 2 2 2 2 2 2 2 2 2 2 2 1 2 2 2 1 2 2 2 1 2 1 2 2 2 2 2 2 2 1 2 2 2
2 2
[1592] 2 2 2 2 2 2 2 2
```

Within cluster sum of squares by cluster:

```
[1] 6810.586 7510.572
(between_SS / total_SS = 18.5 %)
```

Available components:

```
[1] "cluster"      "centers"      "totss"        "withinss"
"tot.withinss"
[6] "betweenss"    "size"         "iter"         "ifault"
```

```
km_clust <- km_wine$cluster
table(km_clust)
```

```
km_clust
 1    2
590 1009
```

```
fviz_cluster(km_wine, data = wine_scaled, geom = "point")
```




Hasil clustering menunjukkan bahwa dari total 1.599 data yang diperiksa, Cluster 1 terdiri dari 590 data dan Cluster 2 terdiri dari 1.009 data. Visualisasi menggunakan PCA menjadi 2 dimensi, dimana sumbu Dim1 menunjukkan 28,2% variasi, dan Dim2 menunjukkan 17,5% variasi, jadi jika kita jumlahkan kedua dimensi itu, mereka mewakili sekitar 45,7% informasi dari data yang asli.

Dari cluster plot yang dibuat, terlihat bahwa Cluster 1 (merah) lebih banyak berada di sisi kanan dengan nilai Dim1 positif, sementara Cluster 2 (wbiru) lebih banyak ada di sisi kiri dengan nilai Dim1 negatif. Kedua cluster ini menunjukkan pemisahan yang jelas, meskipun ada sedikit area di tengah yang bercampur, yang normal karena kedua dimensi hanya menggambarkan sebagian dari total variasi data. Secara keseluruhan, gambar ini menunjukkan bahwa K-Means berhasil membagi 2 kelompok wine yang memiliki ciri yang berbeda satu sama lain.

Hierarchial Clustering

```
## Matriks Jarak  
set.seed(123)
```

```

dist_wine <- dist(wine_scaled, method = "euclidean")

## Pemilihan Linkage Terbaik (Agglomerative Coefficient) --
linkage_methods <- c("average", "single", "complete", "ward")
names(linkage_methods) <- c("Average", "Single", "Complete", "Ward")

ac_values <- sapply(linkage_methods, function(m) round(agnes(wine_scaled,
method = m)$ac, 4))

data.frame(Linkage = names(ac_values),
           Agglomerative_Coefficient = ac_values,
           row.names = NULL)

```

	Linkage	Agglomerative_Coefficient
1	Average	0.9199
2	Single	0.8729
3	Complete	0.9548
4	Ward	0.9881

Untuk membuat model Hierarchical Clustering, gunakan cara *Euclidean Distance* untuk mengukur jarak antara data yang berbeda. Setelah itu, tentukan metode linkage terbaik berdasarkan nilai *Agglomerative Coefficient (AC)*. Nilai AC yang mendekati 1 menandakan bahwa struktur cluster lebih kuat. Dari empat cara linkage yang diuji, cara **Ward memberikan nilai AC tertinggi** yaitu 0.9881, jadi cara ini dipilih sebagai yang terbaik untuk analisis Hierarchical Clustering berikutnya.

```

# => Linkage dengan AC tertinggi dipilih (Ward)

## Pemodelan menggunakan Ward's Linkage
hc_ward <- hclust(dist_wine, method = "ward.D2")

plot(
  hc_ward, labels = FALSE, hang = -1,
  main = "Dendrogram Hierarchical Clustering"
)

rect.hclust(
  hc_ward,
  k = 2,
  border = "green"
)

```

```
cl_ward <- cutree(hc_ward, k = 2)
cl_ward
```

[illegible]

[371] 1 2 1 1 2 2 2 2 2 1 2 2 2 2 1 1 1 1 1 1 2 2 1 2 2 1 2 2 1 1 2 2 2 1
2 2
[408] 2 2 1 1 1 1 2 1 1 2 1 2 1 1 1 1 2 1 1 1 1 2 2 2 1 2 2 1 2 1 2 1 1 2 2
2 2
[445] 1 1 1 1 1 2 2 2 1 2 2 2 1 1 2 2 2 1 2 1 2 2 1 2 2 1 2 1 1 2 2 1 2 2 1
1 1
[482] 2 2 2 2 1 1 1 1 2 1 2 2 1 1 2 1 1 2 1 1 2 2 2 2 2 2 2 1 2 1 1 2 2 2 1
2 2
[519] 2 1 2 1 1 1 1 1 1 1 1 1 2 2 2 2 2 2 1 1 2 2 1 2 1 1 2 1 1 2 1 2 1 1 1
1 2
[556] 2 2 2 2 2 2 1 1 1 2 2 2 2 2 1 2 1 2 1 1 1 1 1 1 1 2 2 2 2 1 1 2 1 1 2
1 1
[593] 1 2 1 1 2 2 1 2 1 2 1 2 1 1 2 1 1 1 1 2 1 2 1 1 1 2 2 2 1 1 1 2 1 1 1
1 1
[630] 1 1 2 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 2 1 2 2 2 1 2 2 2 1 2 1 1 2
2 1
[667] 2 2 1 2 1 1 1 1 2 2 2 1 1 1 2 1 1 1 1 1 1 1 1 2 1 1 2 1 1 1 1 1 2 1
1 1
[704] 1 1 1 1 1 1 2 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 2 1 1 1 1 1 1 1
1 1
[741] 1 1 1 1 1 1 1 1 1 1 1 1 1 1 2 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 2 2
1 1
[778] 1 1 1 1 1 1 1 1 2 2 1 1 1 1 1 1 1 2 1 1 2 2 2 1 1 1 1 1 2 2 2 2 1 1 2
1 2
[815] 2 1 2 2 1 1 1 1 1 1 1 2 1 1 1 1 1 1 1 1 1 1 2 1 2 1 1 1 1 1 1 1 1
1 2
[852] 2 1 1 1 1 1 2 2 1 1 1 1 1 1 1 1 1 1 1 1 2 2 2 1 1 1 1 1 1 2 1 1 1
1 1
[889] 1 1 1 1 2 1 1 1 2 1 2 1 2 1 1 1 1 1 1 1 2 2 2 2 2 2 2 1 1 1 1 2 1 1
1 2
[926] 1 1 1 2 2 1 1 1 1 1 2 2 2 2 1 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 1 1
2 1
[963] 1 2 2 1 2 1 2 1 2 2 2 2 2 1 1 1 2 2 2 1 1 2 2 1 2 1 1 2 1 1 1 1 1 1
1 1
[1000] 1 2 1 2 2 1 2 2 2 2 1 2 2 1 1 1 2 2 1 1 1 2 2 1 2 1 1 2 1 1 1 1 1 1
1 2
[1037] 2 1 2 1 1 1 1 2 2 1 1 1 2 2 1 2 1 2 1 1 2 1 1 2 2 2 2 2 1 1 1 2 2 1 2
1 1
[1074] 1 1 1 2 2 2 1 2 1 1 1 1 1 2 2 2 2 2 2 1 2 1 2 1 2 2 2 2 2 1 2 2 1 2 2
1 1
[1111] 1 1 2 2 1 1 1 1 1 1 2 1 1 1 1 2 2 1 1 1 1 1 2 1 2 2 2 2 1 1 1 1 2 1
1 2
[1148] 2 2 2 2 1 1 1 1 1 1 1 2 1 2 2 2 1 1 2 1 1 2 2 2 1 2 1 1 1 1 1 1 2 2 2
1 1
[1185] 1 2 1 2 1 1 2 1 2 1 1 1 1 1 2 1 1 2 2 1 2 2 2 1 2 2 1 1 1 2 2 2 1 1 2
2 1
[1222] 1 1 2 2 1 1 1 1 1 2 1 1 2 1 1 1 1 1 1 1 2 1 1 1 1 1 2 1 1 1 1 1 1 1
1 1
[1259] 1 1 2 1 1 1 2 1 1 2 1 1 1 1 1 1 1 1 2 1 1 2 1 1 1 1 1 1 2 1 1 1 1 1
1 1

```

[1296] 1 1 1 1 1 1 1 2 2 1 1 1 1 1 1 1 1 1 1 1 2 1 2 1 1 2 2 1 1 1 1 1 1
1 1
[1333] 1 1 1 1 1 1 1 1 1 1 1 1 2 1 1 1 1 1 1 1 1 1 1 1 1 2 1 1 2 1 1 1 1
1 1
[1370] 1 2 2 2 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 2 2
1 2
[1407] 1 1 1 1 1 2 1 1 2 1 2 2 1 1 1 1 1 1 2 2 2 2 1 1 1 1 1 1 1 1 1 1 2
1 1
[1444] 1 1 1 1 1 1 2 2 2 1 1 2 1 1 1 2 2 1 1 1 1 1 1 1 1 1 1 1 2 1 1 1 1
1 2
[1481] 1 2 2 2 1 1 1 1 1 1 2 1 1 1 1 1 1 1 1 1 1 2 2 1 1 2 2 2 1 1 1 1 1
1 2
[1518] 1 2 1 1 1 2 1 1 1 1 1 1 1 1 1 1 1 1 1 1 1 2 1 2 2 1 1 1 1 2 1 1
1 1
[1555] 1 1 1 1 1 1 1 1 1 1 1 2 1 1 1 2 1 1 1 2 2 1 1 1 2 1 1 1 2 2 1 1 1
1 1
[1592] 1 1 1 1 1 1 1 2

```

```
table(cl_ward)
```

```


cl_ward
  1    2
1114 485

```

```

fviz_cluster(
  list(
    data = wine_scaled,
    cluster = cl_ward
  ),
  geom = "point",
  ellipse.type = "convex",
  main = "Cluster Hierarchical"
)

```



Model Hierarchical Clustering dibuat menggunakan metode Ward's Linkage, yang menghasilkan dendrogram yang terbagi menjadi 2 cluster utama yang dipisahkan pada height sekitar 65-70. . Ini menunjukkan bahwa kedua cluster tersebut mempunyai karakteristik yang sangat berbeda. Hasil pemotongan dendrogram menggunakan `cutree()` dengan $k = 2$ menghasilkan Cluster 1 yang terdiri dari 1.114 data dan Cluster 2 yang terdiri dari 485 data dari total 1.599 observasi.

Visualisasi dengan PCA menunjukkan bahwa Cluster 1 (merah) mendominasi di sisi kiri dengan penyebaran yang lebih luas, sementara Cluster 2 (biru) berada di sisi kanan dengan penyebaran yang lebih rapat, dengan sedikit tumpang tindih di area tengah pada Dim1 (28.2%) dan Dim2 (17.5%).

Validasi (evaluasi) Cluster


```
sil_kmeans <- silhouette(km_clust, dist_wine)
sil_ward   <- silhouette(cl_ward, dist_wine)

avg_sil_kmeans <- mean(sil_kmeans[, 3])
```

```
avg_sil_ward <- mean(sil_ward[, 3])
```

```
fviz_silhouette(sil_kmeans)
```


	cluster	size	ave.sil.width
1	1	590	0.12
2	2	1009	0.27



Validasi model K-Means menggunakan Silhouette menghasilkan rata-rata Silhouette Score yang didapat adalah 0.21, di mana Cluster 1 mendapatkan nilai 0.12 dan Cluster 2 mendapatkan nilai 0.27. Cluster 2 menunjukkan pemisahan yang lebih baik daripada Cluster 1, namun kedua nilai tersebut masih dianggap rendah karena berada di bawah 0.5.

```
fviz_silhouette(sil_ward)
```

	cluster	size	ave.sil.width
1	1	1114	0.19
2	2	485	0.16



Sementara itu, model Hierarchical Clustering dengan menggunakan Silhouette, diperoleh rata-rata sebesar 0.18, di mana Cluster 1 mendapat nilai 0.19 dan Cluster 2 mendapat nilai 0.16. Kedua cluster memiliki nilai yang cukup mirip tetapi keduanya tetap walaupun rendah, ini menunjukkan bahwa ada tumpang tindih antara cluster di dataset wine ini

Kesimpulan

Dari perbandingan kedua metode, K-Means menunjukkan nilai Silhouette Score yang lebih tinggi (0.21 lebih besar dari 0.18), yang artinya K-Means membentuk kelompok yang lebih padat dan terpisah dengan baik dibandingkan Hierarchical Clustering. Meski begitu, kedua nilai ini masih dianggap rendah karena berada di bawah 0.5, yang menunjukkan bahwa ada tumpang tindih antara kelompok dalam dataset wine ini.

Membandingkan Hasil Kedua Metode

```
hasil_validasi <- data.frame(  
  Metode = c("K-Means Clustering", "HC - Ward's Linkage"),
```



```

    Avg_Silhouette_Score = round(c(avg_sil_kmeans, avg_sil_ward), 4),
    Keterangan           = ifelse(c(avg_sil_kmeans, avg_sil_ward) ==
max(avg_sil_kmeans, avg_sil_ward),
                                "TERBAIK", "-")
)

print(hasil_validasi)

```

	Metode	Avg_Silhouette_Score	Keterangan
1	K-Means Clustering	0.2137	TERBAIK
2	HC - Ward's Linkage	0.1834	-

Berdasarkan perbandingan antara kedua model, K-Means Clustering dipilih sebagai model yang paling baik karena memiliki nilai Average Silhouette Score tertinggi yaitu 0.2137, sementara Hierarchical Clustering Ward's Linkage hanya mendapatkan nilai 0.1834. Ini berarti K-Means menciptakan kelompok yang lebih teratur dan terpisah dengan baik dalam dataset wine ini.

Karakteristik Tiap Cluster

K-Means Clustering

```

wine$Cluster <- km_wine$cluster

aggregate(. ~ Cluster,
          data = wine,
          FUN = mean)

```

	Cluster	fixed acidity	volatile acidity	citric acid	residual sugar
chlorides					
1	1	9.922712	0.4139068	0.4628814	2.765763
0.09990000					
2	2	7.382260	0.5944301	0.1587611	2.406095
0.08019623					
		free sulfur dioxide	total sulfur dioxide	density	pH
1		13.41017	39.38814	0.9976893	3.201847
2		17.31615	50.60753	0.9961955	3.375005
sulphates					
		0.6054708			
		alcohol	quality		
1		10.60740	5.894915		
2		10.31515	5.484638		

Cluster 1 (590 data) adalah kelompok wine yang memiliki fixed acidity yang lebih tinggi (9,92), citric acid yang lebih tinggi (0,46), sulphates yang lebih tinggi (0,75), serta densitas yang lebih tinggi (0,9977). Selain itu, cluster ini memiliki volatile acidity yang lebih rendah (0,41) dan nilai pH yang lebih rendah (3,20). Rata-rata kualitas wine dari cluster ini sebesar 5,89, yang lebih

tinggi dibandingkan cluster lainnya. Karakteristik ini menunjukkan bahwa Cluster 1 biasanya berisi anggur yang memiliki keasaman lebih tinggi dan kualitas yang lebih baik.

Cluster 2 (1.009 data) adalah kelompok wine yang mempunyai volatile acidity yang tinggi (0.59), free sulfur dioxide yang tinggi (17.32), total sulfur dioxide yang tinggi (50.61), dan pH yang tinggi (3.38). Namun, cluster ini memiliki fixed acidity yang rendah (7.38) dan citric acid yang rendah (0.16). Rata-rata kualitas wine dari cluster ini lebih rendah (5.48) jika dibandingkan dengan Cluster 1.

Hierarchical Clustering

```
wine$Cluster_HC <- cl_ward
```

```
aggregate(. ~ Cluster_HC,  
          data = wine,  
          mean)
```

	Cluster_HC	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	quality	Cluster
1	1	7.733573	0.5873968	0.1872621	2.558079	0.08231149	18.38959	54.64542	0.9965869	3.351813	0.6228905	10.22557	5.447935	1.846499
2	2	9.665773	0.3909794	0.4632577	2.494536	0.09930722	10.09897	27.68454	0.9971137	3.217629	0.7391340	10.87643	6.068041	1.136082

Cluster 1 (1.114 data) adalah kelompok wine yang memiliki sifat dengan volatile acidity tinggi (0.59), free sulfur dioxide tinggi (18.39), total sulfur dioxide tinggi (54.65), dan pH yang juga tinggi (3.35). Namun, kelompok ini memiliki fixed acidity yang rendah (7.73) dan citric acid yang rendah (0.19). Rata-rata kualitas wine dalam kelompok ini lebih rendah (5.45) jika dibandingkan dengan Cluster 2.

Cluster 2 (485 data) adalah kelompok anggur dengan sifat yang menunjukkan fixed acidity tinggi (9.67), citric acid tinggi (0.46), sulphates tinggi (0.74), dan kadar alkohol tinggi (10.88). Meskipun begitu, kelompok ini memiliki volatile acidity yang rendah (0.39) dan total sulfur dioxide yang rendah (27.68). Rata-rata kualitas wine di kelompok ini lebih tinggi (6.07) dibandingkan dengan Cluster 1.